



Aprendizagem Automática




João Paulo Pordeus Gomes



Aula Anterior

Regressão Linear

► $\bar{y}_i = w_1 x_i + w_0$



Regressão Linear Multivariada

- ▶ Em diversos problemas é necessário utilizar mais de uma variável x para tentar explicar a variável de saída y
 - ▶ Exemplo
 - ▶ Concessão de crédito

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000
...		...
5500	1700	52000



Gradiente Descendente Estocástico

- ▶ Regressão Linear Multivariada

- ▶ $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$

- ▶ Regra de Aprendizado

- ▶ $\mathbf{w} = \mathbf{w} + \alpha e_i \mathbf{x}_i$



Regressão Linear (em lote - *batch*)

- ▶ Modelo

- ▶ $\bar{Y} = Xw$

- ▶ Regra de Aprendizado

- ▶ $w = (X^T X)^{-1} X^T Y$



Gradiente Descendente Estocástico

- ▶ Define α pequeno
- ▶ Utiliza todo o conjunto de dados e atualiza os pesos
 - ▶ $w_0 = w_0 + \alpha e_i$
 - ▶ $w_1 = w_1 + \alpha e_i x_i$
- ▶ Faz permutação nos dados
- ▶ Repete o procedimento diversas vezes (épocas)



Criando Modelos Não Lineares

Modelos não-Lineares com Regressão Linear

- ▶ É possível criar regressões não lineares através da formulação linear do problema.
 - ▶ Relação entre as variáveis é reconhecidamente não linear (quadrática, cúbica ...)



Modelos não-Lineares com Regressão Linear

- ▶ É possível criar regressões não lineares através da formulação linear do problema
- ▶ Criar novos atributos



Modelos não-Lineares com Regressão Linear

- ▶ É possível criar regressões não lineares através da formulação linear do problema
- ▶ Criar novos atributos

Salário (R\$)	Crédito (R\$)
1500	16500
2000	18000
3000	28000
...	...
5500	52000



Modelos não-Lineares com Regressão Linear

- ▶ É possível criar regressões não lineares através da formulação linear do problema
- ▶ Criar novos atributos

Salário (R\$)	Salário ² (R\$ ²)	Crédito (R\$)
1500	1500 ²	16500
2000	2000 ²	18000
3000	3000 ²	28000
...		...
5500	5500 ²	52000



Modelos não-Lineares com Regressão Linear

- ▶ É possível criar regressões não lineares através da formulação linear do problema
- ▶ Criar novos atributos
 - ▶ $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$
 - ▶ $\mathbf{x}_1 = [1 \ 1500 \ 1500^2]^T$, $\mathbf{x}_2 = [1 \ 2000 \ 2000^2]^T$, ...
 - ▶ $\mathbf{w}^T = [w_0 \ w_1 \ w_2]$

Salário (R\$)	Salário ² (R\$ ²)	Crédito (R\$)
1500	1500 ²	16500
2000	2000 ²	18000
3000	3000 ²	28000
...		...
5500	5500 ²	52000



A vertical blue bar is located on the left side of the slide, partially enclosed by a thin white rectangular border.

Regularização

Regressão Linear


Overfitting

- ▶ Modelo se ajusta demasiadamente aos dados utilizados para encontrar os parâmetros



Overfitting


► Exemplo



Overfitting

- ▶ Exemplo


- ▶ Erro = 6.54



Overfitting

- ▶ Exemplo


- ▶ Erro = 2.24



Overfitting

► Exemplo


► Erro = 27.77



Overfitting

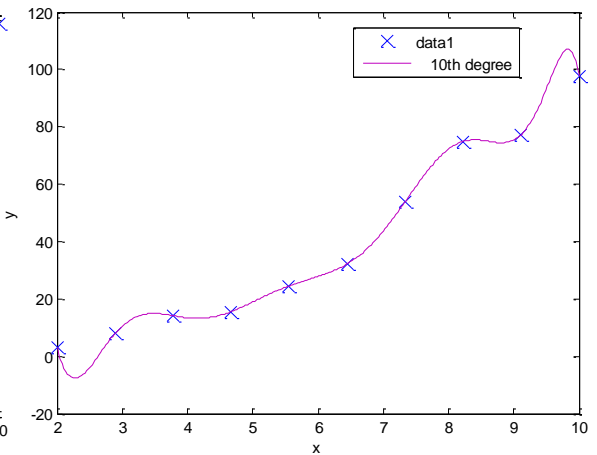


► Exemplo

► Erro = 15.18




Overfitting

- Modelo se ajusta demasiadamente aos dados utilizados para encontrar os parâmetros





Overfitting

- Modelo se ajusta demasiadamente aos dados utilizados para encontrar os parâmetros



Alto Bias



Alto Variância

Evitar Overfitting



Evitar Overfitting

- ▶ Conjuntos de treino e teste



Evitar Overfitting

- ▶ Conjuntos de treino e teste
- ▶ Regularização



Tamanho do Modelo

- ▶ Como ajustar o tamanho do modelo ?
 - ▶ Exemplo
 - ▶ Diversas Variáveis
 - Concessão de crédito com muitas variáveis de entrada
 - $\bar{y} = w_1x_1 + w_0$
 - $\bar{y} = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + w_0$
 - ▶ Modelo de grau maior
 - $\bar{y} = w_1x_1 + w_0$
 - $\bar{y} = w_1x_1 + w_1x_1^2 + w_1x_1^3 + w_1x_1^4 + w_0$



Regularização

- ▶ Diminuir o valor dos coeficientes do modelo associados a variáveis que menos influenciam no resultado.



Regularização

- ▶ Diminuir o valor dos coeficientes do modelo associados a variáveis que menos influenciam no resultado.
- ▶ Modelo com muitos parâmetros ficará semelhante a um modelo com menos parâmetros
 - ▶ $\bar{y} = w_1x_1 + w_0$
 - ▶ $\bar{y} = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + w_0$





Regularização

- ▶ Diminuir o valor dos coeficientes do modelo associados a variáveis que menos influenciam no resultado.
- ▶ Modelo com muitos parâmetros ficará semelhante a um modelo com menos parâmetros

□ $\bar{y} = w_1 x_1 + w_0$

□ $\bar{y} = w_1 x_1 + w_1 x_1^2 + w_0$



Regularização

- ▶ Regressão Linear

- ▶ Função Objetivo

- ▶ $J(\mathbf{w}) = \frac{1}{2n} \sum_{i=1}^n (y_i - \bar{y}_i)^2$



Regularização

- ▶ Regressão Linear

- ▶ Função Objetivo

- ▶ $J(\mathbf{w}) = \frac{1}{2n} \sum_{i=1}^n (y_i - \bar{y}_i)^2$

- ▶ Regressão Linear com regularização

- ▶ Função Objetivo

- ▶ $J(\mathbf{w}) = \frac{1}{2n} [\sum_{i=1}^n (y_i - \bar{y}_i)^2 + \lambda \sum_{j=1}^m w_j^2]$



Regularização

► $\min_{\mathbf{w}} J(\mathbf{w}) = \frac{1}{2n} [\sum_{i=1}^n (y_i - \bar{y}_i)^2 + \lambda \sum_{j=1}^m w_j^2]$



Regularização

- ▶ $\min_{\mathbf{w}} J(\mathbf{w}) = \frac{1}{2n} [\sum_{i=1}^n (y_i - \bar{y}_i)^2 + \lambda \sum_{j=1}^m w_j^2]$
- ▶ Utilizando o método dos mínimos quadrados
 - ▶ $\frac{\partial J}{\partial w_0} = \frac{1}{2n} 2[\sum_{i=1}^n e_i(-1)] = -\frac{1}{n} \sum_{i=1}^n e_i$



Regularização

- ▶ $\min_{\mathbf{w}} J(\mathbf{w}) = \frac{1}{2n} [\sum_{i=1}^n (y_i - \bar{y}_i)^2 + \lambda \sum_{j=1}^m w_j^2]$
- ▶ Utilizando o método dos mínimos quadrados
 - ▶ $\frac{\partial J}{\partial w_0} = \frac{1}{2n} 2[\sum_{i=1}^n e_i(-1)] = -\frac{1}{n} \sum_{i=1}^n e_i$
 - ▶ $\frac{\partial J}{\partial w_j} = \frac{1}{2n} 2[\sum_{i=1}^n e_i(-x_{ij}) + \frac{\lambda}{n} w_j] = -\frac{1}{n} \sum_{i=1}^n e_i x_{ij} - \frac{\lambda}{n} w_j$



Regularização

- ▶ $\frac{\partial J}{\partial w_0} = -\frac{1}{n} \sum_{i=1}^n e_i$
- ▶ $\frac{\partial J}{\partial w_j} = -\frac{1}{n} \sum_{i=1}^n e_i x_{ij} + \frac{\lambda}{n} w_j$
- ▶ As equações de atualização dos pesos serão:
 - ▶ $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$
 - ▶ $w_j = w_j + \alpha \left[\frac{1}{n} \sum_{i=1}^n e_i x_{ij} - \frac{\lambda}{n} w_j \right]$



Regularização

- ▶ Efeito do λ

- ▶ Função Objetivo

- ▶ $J(\mathbf{w}) = \frac{1}{2n} [\sum_{i=1}^n (y_i - \bar{y}_i)^2 + \lambda \sum_{j=1}^m w_j^2]$

- ▶ Atualização

- ▶ $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$

- ▶ $w_j = w_j + \alpha [\frac{1}{n} \sum_{i=1}^n e_i x_{ij} - \frac{\lambda}{n} w_j]$



Regressão Linear

- ▶ Gradiente Descendente
- ▶ Mínimos Quadrados (batch)



Mínimos Quadrados

- ▶ Modelo

- ▶ $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - \bar{Y})^T (Y - \bar{Y})$

- ▶ $J(\mathbf{w}) = \frac{1}{2} (Y - X\mathbf{w})^T (Y - X\mathbf{w})$



Mínimos Quadrados Regularizado

- ▶ Modelo

- ▶ $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶ $J(\mathbf{w}) = \frac{1}{2} [(Y - \bar{Y})^T (Y - \bar{Y}) + \lambda \mathbf{w}^T \mathbf{w}]$

- ▶ $J(\mathbf{w}) = \frac{1}{2} [(Y - X\mathbf{w})^T (Y - X\mathbf{w}) + \lambda \mathbf{w}^T \mathbf{w}]$



Mínimos Quadrados Regularizado

- ▶ Modelo

- ▶ $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶ $J(\mathbf{w}) = \frac{1}{2} [(Y - \bar{Y})^T (Y - \bar{Y}) + \lambda \mathbf{w}^T \mathbf{w}]$

- ▶ $J(\mathbf{w}) = \frac{1}{2} [(Y - X\mathbf{w})^T (Y - X\mathbf{w}) + \lambda \mathbf{w}^T \mathbf{w}]$

- ▶ Derivando em relação a \mathbf{w}



Mínimos Quadrados Regularizado

- ▶ Modelo

- ▶ $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶ $J(\mathbf{w}) = \frac{1}{2}[(Y - \bar{Y})^T(Y - \bar{Y}) + \lambda\mathbf{w}^T\mathbf{w}]$

- ▶ $J(\mathbf{w}) = \frac{1}{2}[(Y - X\mathbf{w})^T(Y - X\mathbf{w}) + \lambda\mathbf{w}^T\mathbf{w}]$

- ▶ Derivando em relação a \mathbf{w}

- ▶ $\frac{1}{2}2[(-X)^T(Y - X\mathbf{w}) + \lambda\mathbf{w}] = \mathbf{0}$



Mínimos Quadrados Regularizado

- ▶ Modelo

- ▶ $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶ $J(\mathbf{w}) = \frac{1}{2} [(Y - \bar{Y})^T (Y - \bar{Y}) + \lambda \mathbf{w}^T \mathbf{w}]$

- ▶ $J(\mathbf{w}) = \frac{1}{2} [(Y - X\mathbf{w})^T (Y - X\mathbf{w}) + \lambda \mathbf{w}^T \mathbf{w}]$

- ▶ Derivando em relação a \mathbf{w}

- ▶ $\frac{1}{2} 2 [(-X)^T (Y - X\mathbf{w}) + \lambda \mathbf{w}] = \mathbf{0}$

- ▶ $-X^T (Y - X\mathbf{w}) + \lambda \mathbf{w} = \mathbf{0}$

- ▶ $X^T X \mathbf{w} + \lambda \mathbf{w} = X^T Y$

- ▶ $(X^T X + \lambda I) \mathbf{w} = X^T Y$

- ▶ $\mathbf{w} = (X^T X + \lambda I)^{-1} X^T Y$



Mínimos Quadrados Regularizado

- ▶ Modelo
 - ▶ $\bar{Y} = Xw$
- ▶ Regra de ajuste dos pesos
 - ▶ $w = (X^T X + \lambda I)^{-1} X^T Y$



Mínimos Quadrados Regularizado

- ▶ Modelo
 - ▶ $\bar{Y} = Xw$
- ▶ Regra de ajuste dos pesos
 - ▶ $w = (X^T X + \lambda I)^{-1} X^T Y$
- ▶ Não utilizar regularização no termo w_0



Mínimos Quadrados Regularizado

- ▶ Modelo

- ▶ $\bar{Y} = Xw$

- ▶ Regra de ajuste dos pesos

- ▶ $w = (X^T X + \lambda I)^{-1} X^T Y$

- ▶ Não utilizar regularização no termo w_0

- ▶ Fazer o primeiro termo de λI igual a zero



Mínimos Quadrados Regularizado

- ▶ Modelo

- ▶ $\bar{Y} = Xw$

- ▶ Regra de ajuste dos pesos

- ▶ $w = (X^T X + \lambda I)^{-1} X^T Y$

- ▶ Não utilizar regularização no termo w_0

- ▶ Fazer o primeiro termo de λI igual a zero

- ▶ Exemplo

- ▶ $\lambda I = \begin{bmatrix} \lambda & 0 & 0 \\ 0 & \lambda & 0 \\ 0 & 0 & \lambda \end{bmatrix}$



Mínimos Quadrados Regularizado

- ▶ Modelo

- ▶ $\bar{Y} = Xw$

- ▶ Regra de ajuste dos pesos

- ▶ $w = (X^T X + \lambda I)^{-1} X^T Y$

- ▶ Não utilizar regularização no termo w_0

- ▶ Fazer o primeiro termo de λI igual a zero

- ▶ Exemplo

- ▶ $\lambda I = \begin{bmatrix} 0 & 0 & 0 \\ 0 & \lambda & 0 \\ 0 & 0 & \lambda \end{bmatrix}$





Dúvidas ?