

# Aprendizagem Automática

João Paulo Pordeus Gomes

# Regressão Linear Univariada

# Regressão Linear

---

- ▶ Explicar uma determinada variável de saída ( $y$ ) através de variáveis de entrada ( $x$ ), utilizando um modelo linear.



# Regressão Linear

---

- ▶ Explicar uma determinada variável de saída ( $y$ ) através de variáveis de entrada ( $x$ ), utilizando um modelo linear.
- ▶ Exemplo
  - ▶ Concessão de crédito



# Regressão Linear

---

## ► Concessão de Crédito

Salário (R\$)	Crédito (R\$)
1500	16500
2000	18000
3000	28000
3300	33000
4200	49000
...	...
5500	52000



# Regressão Linear

---

## ► Concessão de Crédito

- Encontrar uma relação linear entre Salário e Credito

Salário (R\$)	Crédito (R\$)
1500	16500
2000	18000
3000	28000
3300	33000
4200	49000
...	...
5500	52000



# Regressão Linear

---

## ► Concessão de Crédito

- Encontrar uma relação linear entre Salário e Credito
- Salário ( $x_i$ ) e Crédito ( $y_i$ )

Salário (R\$)	Crédito (R\$)
1500	16500
2000	18000
3000	28000
3300	33000
4200	49000
...	...
5500	52000



# Regressão Linear

---

## ► Concessão de Crédito

- Encontrar uma relação linear entre Salário e Credito
- Salário ( $x_i$ ) e Crédito ( $y_i$ )
- $\bar{y}_i = w_1 x_i + w_0$

Salário (R\$)	Crédito (R\$)
1500	16500
2000	18000
3000	28000
3300	33000
4200	49000
...	...
5500	52000






# Regressão Linear

---


►  $\bar{y}_i = w_1 x_i + w_0$



# Regressão Linear

---


►  $\bar{y}_i = w_1 x_i + w_0$



# Regressão Linear

---

►  $\bar{y}_i = w_1 x_i + w_0$



# Regressão Linear

---

- ▶  $\bar{y}_i = w_1 x_i + w_0$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n e_i^2$ 
  - ▶ Onde:  $e_i = y_i - \bar{y}_i$



# Regressão Linear

---

- ▶  $\bar{y}_i = w_1 x_i + w_0$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n e_i^2$ 
  - ▶ Onde:  $e_i = y_i - \bar{y}_i$
- ▶  $\min_{w_1 w_0} J(w_1, w_0)$



# Regressão Linear

---

- ▶  $\bar{y}_i = w_1 x_i + w_0$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n e_i^2$ 
  - ▶ Onde:  $e_i = y_i - \bar{y}_i$
- ▶  $\min_{w_1 w_0} J(w_1, w_0)$ 
  - ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - \bar{y}_i)^2$



# Regressão Linear

---


- ▶  $\bar{y}_i = w_1 x_i + w_0$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n e_i^2$ 
  - ▶ Onde:  $e_i = y_i - \bar{y}_i$
- ▶  $\min_{w_1 w_0} J(w_1, w_0)$ 
  - ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - \bar{y}_i)^2$
  - ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$



# Regressão Linear

---

►  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$






# Regressão Linear

---


- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$ 
  - ▶ Método do gradiente descendente



# Gradiente Descendente


---

- ▶ Inicializar os pontos de forma aleatória
  - ▶  $w_1, w_0$
- ▶ Movimento os pontos para a direção que diminui J



# Gradiente Descendente

- ▶ Inicializar os pontos de forma aleatória
  - ▶  $w_1, w_0$
- ▶ Movimento os pontos para a direção que diminui J
  - ▶  $w = w - \alpha \frac{\partial J}{\partial w}$



# Gradiente Descendente

---

- ▶  $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$



# Gradiente Descendente

---

- ▶  $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶  $\frac{\partial J}{\partial w_0} = ?$



# Gradiente Descendente

---

- ▶  $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶  $\frac{\partial J}{\partial w_0} = \left[ \frac{1}{2n} 2 \sum_{i=1}^n (y_i - w_1 x_i - w_0) \right] (-1)$



# Gradiente Descendente

---

- ▶  $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶  $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$



# Gradiente Descendente

---

- ▶  $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶  $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$ 
  - ▶  $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$





# Gradiente Descendente

---

- ▶  $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶  $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$ 
  - ▶  $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$
- ▶  $\frac{\partial J}{\partial w_1} = ?$



# Gradiente Descendente

---

- ▶  $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶  $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$ 
  - ▶  $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$
- ▶  $\frac{\partial J}{\partial w_1} = [\frac{1}{2n} 2 \sum_{i=1}^n (y_i - w_1 x_i - w_0)](-x_i)$



# Gradiente Descendente

---

- ▶  $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶  $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$ 
  - ▶  $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$
- ▶  $\frac{\partial J}{\partial w_1} = (\frac{1}{2n} 2 \sum_{i=1}^n e_i)(-x_i)$



# Gradiente Descendente

---

- ▶  $w = w - \alpha \frac{\partial J}{\partial w}$
- ▶  $J(w_1, w_0) = \frac{1}{2n} \sum_{i=1}^n (y_i - w_1 x_i - w_0)^2$
- ▶  $\frac{\partial J}{\partial w_0} = [\frac{1}{2n} 2 \sum_{i=1}^n e_i](-1)$ 
  - ▶  $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$
- ▶  $\frac{\partial J}{\partial w_1} = (\frac{1}{2n} 2 \sum_{i=1}^n e_i)(-x_i)$ 
  - ▶  $w_1 = w_1 + \alpha \frac{1}{n} \sum_{i=1}^n e_i x_i$



# Gradiente Descendente

---

- ▶ Regressão Linear Univariada

- ▶  $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$

- ▶  $w_1 = w_1 + \alpha \frac{1}{n} \sum_{i=1}^n e_i x_i$



# Gradiente Descendente

---

- ▶ Define  $\alpha$  pequeno
- ▶ Utiliza todo o conjunto de dados e atualiza os pesos
  - ▶  $w_0 = w_0 + \alpha \frac{1}{n} \sum_{i=1}^n e_i$
  - ▶  $w_1 = w_1 + \alpha \frac{1}{n} \sum_{i=1}^n e_i x_i$
- ▶ Repete o procedimento diversas vezes (épocas)



# Gradiente Descendente Estocástico

---

- ▶ Atualização a cada amostra



# Gradiente Descendente Estocástico

---

- ▶ Atualização a cada amostra

- ▶  $w_0 = w_0 + \alpha e_i$

- ▶  $w_1 = w_1 + \alpha e_i x_i$





# Gradiente Descendente Estocástico

---

- ▶ Define  $\alpha$  pequeno
- ▶ Utiliza todo o conjunto de dados e atualiza os pesos
  - ▶  $w_0 = w_0 + \alpha e_i$
  - ▶  $w_1 = w_1 + \alpha e_i x_i$
- ▶ Faz permutação nos dados
- ▶ Repete o procedimento diversas vezes (épocas)



# Regressão Linear Multivariada

# Regressão Linear Multivariada

---

- ▶ Em diversos problemas é necessário utilizar mais de uma variável  $x$  para tentar explicar a variável de saída  $y$



# Regressão Linear Multivariada

---

- ▶ Em diversos problemas é necessário utilizar mais de uma variável  $x$  para tentar explicar a variável de saída  $y$ 
  - ▶ Exemplo
    - ▶ Concessão de crédito



# Regressão Linear Multivariada

---

- ▶ Em diversos problemas é necessário utilizar mais de uma variável  $x$  para tentar explicar a variável de saída  $y$ 
  - ▶ Exemplo
    - ▶ Concessão de crédito

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000
...		...
5500	1700	52000



# Regressão Linear Multivariada

---

## ► Concessão de Crédito

- Encontrar uma relação linear entre Salário, Dívida e Crédito
- Salário ( $x_{1i}$ ), Dívida ( $x_{2i}$ ) e Crédito ( $y_i$ )
- $\bar{y}_i = w_1 x_{1i} + w_2 x_{2i} + w_0$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000
...		...
5500	1700	52000



# Regressão Linear Multivariada

---

►  $\bar{y}_i = w_1x_{1i} + w_2x_{2i} + w_0$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000



# Regressão Linear Multivariada

---

- ▶  $\bar{y}_i = w_1x_{1i} + w_2x_{2i} + w_0$
- ▶  $\bar{y}_i = w_1x_{1i} + w_2x_{2i} + w_0x_0$ 
  - ▶  $x_0 = 1$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000





# Regressão Linear Multivariada

---

- ▶  $\bar{y}_i = w_1 x_{1i} + w_2 x_{2i} + w_0$
- ▶  $\bar{y}_i = w_1 x_{1i} + w_2 x_{2i} + w_0 x_0$ 
  - ▶  $x_0 = 1$
- ▶  $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000



# Regressão Linear Multivariada

---

- ▶  $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$ 
  - ▶  $\mathbf{x}_1 = [1 \ 1500 \ 0]^T$ ,  $\mathbf{x}_2 = [1 \ 2000 \ 4000]^T$ , ...
  - ▶  $\mathbf{w}^T = [w_0 \ w_1 \ w_2]$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000



# Regressão Linear Multivariada

---

- ▶  $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$
- ▶ Para aprender os pesos, pode-se utiliza o gradiente descendente de forma semelhante à apresentada anteriormente.



# Gradiente Descendente

---

- ▶ Regressão Linear Multivariada

- ▶  $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$

- ▶ Regra de Aprendizado

- ▶  $\mathbf{w} = \mathbf{w} + \alpha \frac{1}{n} \sum_{i=1}^n e_i \mathbf{x}_i$



# Gradiente Descendente Estocástico

---

- ▶ Regressão Linear Multivariada

- ▶  $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$

- ▶ Regra de Aprendizado

- ▶  $\mathbf{w} = \mathbf{w} + \alpha e_i \mathbf{x}_i$



## Regressão Linear (em lote - *batch*)

---

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.



# Regressão Linear (em lote - *batch*)

---

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.
- ▶ Exemplo
  - ▶  $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000

# Regressão Linear (em lote - *batch*)

---

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.
- ▶ Exemplo
  - ▶  $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$
  - ▶  $\mathbf{Y} = [y_1 \ y_2 \ \dots \ y_n]^T$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000



# Regressão Linear (em lote - *batch*)

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.
- ▶ Exemplo
  - ▶  $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$
  - ▶  $\mathbf{Y} = [y_1 \ y_2 \ \dots \ y_n]^T$ 
    - ▶  $\mathbf{Y} = [16500 \ 12000 \ 2800]^T$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000

# Regressão Linear (em lote - *batch*)

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.
- ▶ Exemplo
  - ▶  $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$
  - ▶  $\mathbf{Y} = [y_1 \ y_2 \ \dots \ y_n]^T$
  - ▶  $\mathbf{X} = [\mathbf{x}_1 \ \mathbf{x}_2 \ \dots \ \mathbf{x}_n]^T$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000

# Regressão Linear (em lote - *batch*)

- ▶ Se já tivermos todos os pontos, é possível calcular os parâmetros sem utilizar um processo iterativo.
- ▶ Exemplo

- ▶  $\bar{y}_i = \mathbf{w}^T \mathbf{x}_i$

- ▶  $\mathbf{Y} = [y_1 \ y_2 \ \dots \ y_n]^T$

- ▶  $\mathbf{X} = [\mathbf{x}_1 \ \mathbf{x}_2 \ \dots \ \mathbf{x}_n]^T$

- ▶  $\mathbf{X} = \begin{bmatrix} 1 & 1500 & 0 \\ 1 & 2000 & 4000 \\ 1 & 3000 & 2000 \end{bmatrix}$

Salário (R\$)	Dívida (R\$)	Crédito (R\$)
1500	0	16500
2000	4000	12000
3000	2000	28000

# Regressão Linear (em lote - *batch*)

---

- ▶ Modelo

- ▶  $\bar{Y} = Xw$



# Regressão Linear (em lote - *batch*)

---

- ▶ Modelo

- ▶  $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶  $J(\mathbf{w}) = \frac{1}{2} (Y - \bar{Y})^T (Y - \bar{Y})$

- ▶  $J(\mathbf{w}) = \frac{1}{2} (Y - X\mathbf{w})^T (Y - X\mathbf{w})$



# Regressão Linear (em lote - *batch*)

---

- ▶ Modelo

- ▶  $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶  $J(\mathbf{w}) = \frac{1}{2} (Y - \bar{Y})^T (Y - \bar{Y})$

- ▶  $J(\mathbf{w}) = \frac{1}{2} (Y - X\mathbf{w})^T (Y - X\mathbf{w})$

- ▶ Minimizando J (derivando e igualando a zero)



# Regressão Linear (em lote - *batch*)

---

- ▶ Modelo

- ▶  $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶  $J(\mathbf{w}) = \frac{1}{2} (Y - \bar{Y})^T (Y - \bar{Y})$

- ▶  $J(\mathbf{w}) = \frac{1}{2} (Y - X\mathbf{w})^T (Y - X\mathbf{w})$

- ▶ Minimizando J (derivando e igualando a zero)

- ▶  $\frac{\partial J}{\partial \mathbf{w}} = \frac{1}{2} 2(-X^T)(Y - X\mathbf{w}) = 0$



# Regressão Linear (em lote - *batch*)

---

- ▶ Modelo

- ▶  $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶  $J(\mathbf{w}) = \frac{1}{2} (Y - \bar{Y})^T (Y - \bar{Y})$

- ▶  $J(\mathbf{w}) = \frac{1}{2} (Y - X\mathbf{w})^T (Y - X\mathbf{w})$

- ▶ Minimizando J (derivando e igualando a zero)

- ▶  $\frac{\partial J}{\partial \mathbf{w}} = \frac{1}{2} 2(-X^T)(Y - X\mathbf{w}) = 0$

- ▶  $X^T X\mathbf{w} = X^T Y$





# Regressão Linear (em lote - *batch*)

---

- ▶ Modelo

- ▶  $\bar{Y} = X\mathbf{w}$

- ▶ Função de custo

- ▶  $J(\mathbf{w}) = \frac{1}{2} (Y - \bar{Y})^T (Y - \bar{Y})$

- ▶  $J(\mathbf{w}) = \frac{1}{2} (Y - X\mathbf{w})^T (Y - X\mathbf{w})$

- ▶ Minimizando J (derivando e igualando a zero)

- ▶  $\frac{\partial J}{\partial \mathbf{w}} = \frac{1}{2} 2(-X^T)(Y - X\mathbf{w}) = 0$

- ▶  $X^T X \mathbf{w} = X^T Y$

- ▶  $\mathbf{w} = (X^T X)^{-1} X^T Y$



# Regressão Linear (em lote - *batch*)

---

- ▶ Modelo
  - ▶  $\bar{Y} = Xw$
- ▶ Regra de Aprendizado
  - ▶  $w = (X^T X)^{-1} X^T Y$

Método dos mínimos quadrados





Dúvidas ?